Descripción del Dataset – Transmilenio

Estudiante:

William Andres Latorre Cifuentes

Docente:

Joaquin Sánchez

Curso:

Inteligencia artificial

Fecha de entrega:

12/04/2026

Ingeniería de Software

Corporación Universitaria Iberoamericana

1. Introducción

En el presente proyecto se desarrolló un conjunto de datos (dataset) con el fin de simular el comportamiento del sistema de transporte masivo TransMilenio en Bogotá.

Debido a la falta de acceso a datos reales, se optó por la creación de un dataset sintético que representa condiciones típicas del sistema, permitiendo aplicar técnicas de aprendizaje automático supervisado y no supervisado.

2. Origen de los datos

El dataset fue generado de manera artificial (sintética), basándose en supuestos realistas del funcionamiento del sistema de transporte, tales como:

- Distancias aproximadas entre estaciones
- Niveles de tráfico en diferentes horarios
- Variación del tiempo de viaje según condiciones

Este enfoque permite simular escenarios reales sin necesidad de datos oficiales.

3. Estructura del dataset

El dataset está compuesto por múltiples registros, donde cada fila representa un posible recorrido entre dos estaciones del sistema.

Cada registro contiene información relevante que permite analizar y predecir el comportamiento del transporte.

4. Variables del dataset

A continuación, se describen las variables utilizadas:

- **Origen**
  - Tipo: Categórica
  - Descripción: Estación de inicio del recorrido
  - Ejemplo: Portal Norte

- **Destino**
  - Tipo: Categórica
  - Descripción: Estación final del recorrido

- Ejemplo: Calle 72

🔹 **Distancia_km**

- Tipo: Numérica
- Descripción: Distancia aproximada entre estaciones en kilómetros
- Ejemplo: 8

🔹 **Tráfico**

- Tipo: Categórica
- Descripción: Nivel de congestión vehicular durante el recorrido
- Valores posibles: bajo, medio, alto

🔹 **Hora**

- Tipo: Numérica
- Descripción: Hora del día en la que se realiza el recorrido
- Ejemplo: 18 (6:00 PM)

🔹 **Tiempo_min**

- Tipo: Numérica
- Descripción: Tiempo estimado del recorrido en minutos
- Nota: Esta es la variable objetivo-utilizada en el aprendizaje supervisado

5. Uso del dataset

El dataset fue utilizado en dos enfoques diferentes:

✔ **Aprendizaje Supervisado**

Se empleó la variable **tiempo_min** como objetivo para entrenar modelos de predicción, como:

- Regresión lineal
- Random Forest

✓ Aprendizaje No Supervisado

Se utilizaron las variables de entrada para identificar patrones en los datos mediante el algoritmo K-Means, sin utilizar la variable objetivo.

6. Importancia del dataset

Este dataset permite:

- Simular el comportamiento del sistema de transporte
- Aplicar técnicas de inteligencia artificial
- Analizar patrones de movilidad
- Predecir tiempos de viaje

7. Conclusiones

El uso de un dataset sintético es una alternativa válida en entornos académicos cuando no se dispone de datos reales.

Este enfoque permite desarrollar, entrenar y evaluar modelos de inteligencia artificial de manera efectiva, facilitando el aprendizaje y la comprensión de técnicas como el aprendizaje supervisado y no supervisado.

8. Referencias

• Benítez, R. (2014). Inteligencia artificial avanzada. Barcelona: Editorial

UOC. https://elibro.net/es/lc/biblioibero/titulos/57582

• Maguiña Pérez, R. A. (2010). Sistemas de inferencia basados en Lógica

Borrosa: Fundamentos y caso de estudio. Revista de investigación de

Sistemas e Informática, 7(1), 91-104

http://sisbib.unmsm.edu.pe/Bibvirtual/Publicaciones/risi/2010_n1/v7n1/a09v

7n1.pdf

• García Infante, J. C. (2009). Sistemas con lógica difusa. Instituto Politécnico Nacional. https://elibro.net/es/lc/biblioibero/titulos/39257

• Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España. https://elibro.net/es/lc/biblioibero/titulos/50116